

Algoritmos y Complejidad

Algoritmos *greedy*

Pablo R. Fillottrani

Depto. Ciencias e Ingeniería de la Computación
Universidad Nacional del Sur

Primer Cuatrimestre 2017



Generalidades

- ▶ los algoritmos *greedy* son algoritmos que toman decisiones de corto alcance, basadas en información inmediatamente disponible, sin importar consecuencias futuras.
- ▶ se usan generalmente para resolver problemas de *optimización*.
- ▶ en general son algoritmos eficientes y fáciles de implementar, si es que funcionan (**no siempre son correctos!!**).



Algoritmos *greedy*

Generalidades

Problema de la mochila

Scheduling de procesos

Códigos de Huffman



Ejemplo

Problema: Dado un conjunto de monedas, ¿cuál es la mínima cantidad de monedas necesarias para pagar n centavos?.

Solución *greedy*: Dar en lo posible monedas de denominación grande.



Características generales de todo algoritmo *greedy*

- ▶ se dispone de un conjunto C de **candidatos** de los cuales se debe seleccionar un subconjunto que optimice alguna propiedad.
- ▶ a medida que avanza el algoritmo, se van seleccionando candidatos y se los coloca en el conjunto S de **candidatos aceptados**, o R de **candidatos rechazados**.



Esquema general para un algoritmo *greedy*

```
C ::= conjunto de candidatos; S ::= {}  
WHILE (C != {} and ! esSolución(S))  
    x ::= selección(C); C ::= C - {x}  
    IF esViable(S + {x})  
        S ::= S + {x}  
    ENDIF  
ENDWHILE  
IF esSolución(S)  
    RETURN S  
ELSE  
    RETURN "No encontré soluciones"  
ENDIF
```



Características generales de todo algoritmo *greedy*

- ▶ existe una función `esSolución()` que determina si un conjunto de candidatos es una **solución**, no necesariamente optimal, del problema.
- ▶ existe una función `esViable()` que determina si un conjunto de candidatos es **posible de ser extendido para formar una solución**, no necesariamente optimal, del problema.
- ▶ existe una función `selección()` que devuelve el **candidato más promisorio** del conjunto de aquellos que todavía no han sido considerados.



Problema de la mochila

Problema: se tienen n objetos (cada objeto i tiene un peso w_i y un valor v_i); y una mochila con capacidad máxima de W . Se pretende encontrar la manera de cargar la mochila de forma que se maximice el valor de lo transportado y se respete su capacidad máxima.

- ▶ se quiere encontrar valores $x_i, 0 \leq x_i \leq 1$ de forma que

$$\text{maximice } \sum_{i=1}^n x_i v_i$$

$$\text{siempre que } \sum_{i=1}^n x_i w_i \leq W$$



- ▶ claramente, si $\sum_{i=1}^n w_i \leq W$ entonces $x_i = 1$ es optimal.
- ▶ los casos interesantes aparecen cuando $\sum_{i=1}^n w_i > W$.
- ▶ se puede implementar un algoritmo *greedy* con diversas estrategias de selección.



Algoritmo *greedy*

```
FOR i ::= 1 TO n
  x[i] ::= 0
ENDFOR
peso ::= 0
WHILE peso < W
  i ::= seleccion() //no definido cómo
  IF peso + w[i] < W
    x[i] ::= 1; peso ::= peso + w[i]
  ELSE
    x[i] ::= (W - peso) / w[i]; peso ::= W
  ENDIF
ENDWHILE; RETURN x
```



Algoritmo *greedy*

- ▶ datos de entrada: arreglos $w[1..n]$, y $v[1..n]$ contienen con los pesos y valores de los objetos.
- ▶ datos de salida: arreglo $x[1..n]$ con la porción de cada elemento que se carga en la mochila.
- ▶ $x[i] = 1$ significa que el objeto i se lleva completo; $x[i] = 0$ que nada se lleva del objeto i ; y $x[i] = r$, $0 < r < 1$ significa que el elemento i se lleva fraccionado.



- ▶ la función `seleccion()` no está especificada.
- ▶ para definirla se pueden considerar tres estrategias diferentes:
 1. seleccionar el elemento de mayor valor
 2. seleccionar el elemento de menor peso
 3. seleccionar el elemento que tenga mayor valor por unidad de peso



Ejemplo de aplicación

- ▶ sea $n = 5$, $W = 100$ y objetos con los siguientes pesos y valores:

	obj. 1	obj. 2	obj. 3	obj. 4	obj. 5
w	10	20	30	40	50
v	20	30	66	40	60

- ▶ las soluciones con las tres estrategias de selección son:

	obj. 1	obj. 2	obj. 3	obj. 4	obj. 5	Valor
Max v_i	0	0	0 1	0 0,5	0 1	146
Min w_i	0 1	0 1	0 1	0 1	0	156
Max v_i/w_i	0 1	0 1	0 1	0	0 0,8	164



- ▶ el ejemplo anterior demuestra que las dos primeras estrategias resultan en algoritmos que no son correctos.
- ▶ ¿es correcta la tercer estrategia?



Correctitud

Teorema 1 (Correctitud del algoritmo greedy para la mochila)

El algoritmo greedy para el problema de la mochila con selección por mayor v_i/w_i siempre encuentra una solución optimal.

Prueba.

Sea $X = (x_1, x_2, \dots, x_n)$ la solución que encuentra el algoritmo, y $Y = (y_1, y_2, \dots, y_n)$ cualquier otra solución viable (o sea tal que $\sum_{i=1}^n y_i w_i \leq W$). Se prueba que $\text{valor}(X) - \text{valor}(Y) \geq 0$, luego X es una solución optimal. \square



Análisis del tiempo de ejecución

- ▶ si se **ordenan los elementos antes del ciclo greedy**, la selección en cada iteración puede hacerse en tiempo constante y el algoritmo es entonces de $\Theta(n \log n)$, determinado por el ordenamiento.
- ▶ si se **usa un heap ordenado por la estrategia de selección**, el tiempo de inicialización cae a $\Theta(n)$, pero cada selección obliga a mantener la estructura (*heapify*) por lo que el algoritmo también resulta de $\Theta(n \log n)$.
- ▶ ¿Cuál de estas dos implementaciones es más conveniente?



Definición del problema

- ▶ se tiene un servidor (que puede ser un procesador, un cajero en un banco, un surtidor de nafta, etc.) que tiene n clientes que servir.
- ▶ el tiempo de servicio requerido por cada cliente es conocido previamente: $t_i, 1 \leq i \leq n$.
- ▶ **Problema:** **SCHEDULING** se quiere encontrar una secuencia de atención al cliente que minimice el tiempo total de espera de los clientes:

$$\text{Tiempo de espera} = \sum_{i=1}^n (\text{tiempo del cliente } i \text{ en el sistema})$$



Algoritmo *greedy*

- ▶ el ejemplo anterior sugiere un algoritmo *greedy* en donde la selección se hace en base al menor tiempo de servicio restante siempre devuelve un algoritmo optimal.

Teorema 2 (Correctitud del algoritmo *greedy* para scheduling)

El algoritmo *greedy* para **SCHEDULING** es correcto.

Prueba.

ejercicio Ayuda: se prueba por el absurdo, suponiendo que existe una mejor solución que la encontrada por el algoritmo *greedy*, y se llega a una contradicción. □



Ejemplo

- ▶ tres clientes numerados 1, 2, 3 con tiempos $t_1 = 5, t_2 = 10, t_3 = 3$

Scheduling	Tiempo de espera
123:	$5 + (5+10) + (5+10+3) = 38$
132:	$5 + (5+3) + (5+3+10) = 31$
213:	$10 + (10+5) + (10+5+3) = 43$
231:	$10 + (10+3) + (10+3+5) = 41$
312:	$3 + (3+5) + (3+5+10) = 29$
321:	$3 + (3+10) + (3+10+5) = 34$

← optimal



Implementación:

- ▶ se ordenan los procesos por orden creciente de tiempo de servicio, y se implementa el ciclo *greedy*.
- ▶ como el cuerpo del ciclo *greedy* es de $\Theta(1)$, y el ciclo no se repite más de n veces, el tiempo del algoritmo en general estará dominado por el tiempo del ordenamiento: $\Theta(n \log n)$.

(ejercicio)

- ▶ existen numerosas variantes de este problema (con más de un procesos, con límites a la espera de los procesos, con ganancia por la ejecución del proceso antes del límite, etc.), la mayoría de las cuales tienen algoritmos *greedy* correctos.



Definición del problema

- ▶ los **códigos de Huffman** se usan para comprimir información eficientemente, logrando una reducción del 20% al 90% (dependiendo de los información original)
- ▶ la información es representada como una secuencia de caracteres, donde cada caracter tiene una **frecuencia** conocida
- ▶ suponemos que cada caracter es representado en **binario**



Definición del problema

- ▶ no todas las codificaciones variables son aceptables. Para que la **decodificación** no produzca ambigüedades, se debe asegurar que *ningún código debe ser prefijo de otro*
- ▶ se puede demostrar siempre se puede alcanzar una compresión optimal usando estos **códigos prefijos**
- ▶ es muy fácil representar los códigos prefijos con un árbol binario en donde cada camino representa el código de la hoja
- ▶ toda codificación optimal es representada por un **árbol completo**, donde cada nodo interno tiene exactamente dos hijos
- ▶ esto significa que si C son los caracteres, se necesita un árbol binario de $|C|$ hojas y $|C| - 1$ nodos internos (**ejercicio**)



Ejemplo

- ▶ se tienen 6 caracteres: a, ..., f. Si se quiere codificar información escrita en estos caracteres con **códigos de longitud fija** se necesitan $\lceil \log_2 6 \rceil = 3$ bits por código.
- ▶ un archivo de 1.000 caracteres necesitará 3.000 bits
- ▶ si se permiten **códigos de longitud variable**, se pueden asignar códigos cortos a caracteres frecuentes y códigos más largos a caracteres poco frecuentes. Es necesario conocer de antemano la frecuencia con la que aparecen los caracteres
- ▶ por ejemplo:

	a	b	c	d	e	f
Frecuencia (%)	45	13	12	16	9	5
Código variable	0	101	100	111	1101	1100

- ▶ sólo $(45 \cdot 1 + 13 \cdot 3 + 12 \cdot 3 + 16 \cdot 3 + 9 \cdot 4 + 5 \cdot 4) \cdot 10 = 2,240$ bits son necesarios con esta codificación



Definición del problema

- ▶ sea para cada $c \in C$, $c.freq$ la frecuencia de c . Si usamos una codificación representada por un árbol T , entonces sea $\delta_T(c)$ la profundidad en T de la hoja con caracter c , o lo que es lo mismo la cantidad de dígitos de la codificación de c
- ▶ el número de bits necesarios para codificar usando T es

$$B(T) = \sum_{c \in C} c.freq * \delta_T(c)$$

- ▶ tomaremos a $B(T)$ como el costo de la codificación T
- ▶ el problema algorítmico **HUFFMAN** consiste entonces en dada una serie de caracteres C con sus frecuencias, encontrar una codificación T optimal en $B(T)$



Algoritmo de codificación de Huffman

- ▶ Huffman diseñó un algoritmo *greedy* de $O(n \log n)$ (**ejercicio**) basado en la E.D. heap

```
n ::= |C|; Q.construirHeap(C)
FOR i ::= 1 TO n
  x ::= Q.extraerMin(); y ::= Q.extraerMin()
  z ::= nuevo Nodo
  z.left ::= x; z.right ::= y
  z.freq ::= x.freq + y.freq
  Q.insertar(z)
ENDFOR
RETURN Q
```



Correctitud

- ▶ sea C' el alfabeto basado en C que se obtiene eliminando x e y , y agregando un nuevo carácter z tal que $z.freq = x.freq + y.freq$.

Lema 4

Sea T' una codificación optimal para C' . Entonces se puede obtener una codificación optimal T para C reemplazando en T' el nodo hoja de z por un nodo interno con dos hijos x e y .

Prueba.

Se muestra por contradicción que a partir de T'' obtenido de aplicar el lema 3 a una codificación mejor que T en C , se obtiene una codificación mejor que T' .



Correctitud

- ▶ sea C un alfabeto en donde cada $c \in C$ tiene frecuencia $c.freq$; y sean $x, y \in C$ los caracteres con menores frecuencias en C .

Lema 3

C tiene una codificación prefija optimal en la cual x e y son los hermanos de máxima profundidad.

Prueba.

Sea T una codificación optimal y $a, b \in C$ los caracteres hermanos de máxima profundidad en T . Suponemos $a.freq \leq b.freq$ y $x.freq \leq y.freq$, luego $x.freq \leq a.freq$ y $y.freq \leq b.freq$. Construimos T' intercambiando en T a con x ; y T'' intercambiando en T' b con y . Se muestra $B(T) - B(T') \geq 0$ y $B(T') - B(T'') \geq 0$. Como T es optimal, entonces T'' también.



Correctitud

Teorema 5

El algoritmo de Huffman produce una codificación optimal.

Prueba.

Por inducción en las iteraciones aplicando el lema 4. □

